SERVICIO NACIONAL DE APRENDIZAJE

SENA

GUÍA DE APRENDIZAJE N.° 1

DATOS, INFORMACIÓN, TOMA DE DECISIONES,

FUENTES Y FORMATOS

PROGRAMA DE FORMACIÓN: Procesamiento de datos para modelos de inteligencia artificial

COMPETENCIA: integración de datos desde múltiples fuentes de datos

RESULTADO DE APRENDIZAJE: alistar los datos para una solución de ia según técnicas de tratamiento de datos y la necesidad del negocio

APRENDICES: Johann Sebastián Jaramillo Ortega

Samuel Vargas Veloza

Natalia Hernandez Saez

03 DE NOVIEMBRE DEL 2026

BOGOTÁ D.C

Tabla de contenido

1 Actividades **3**

1.1 Actividad de reflexión inicial 3

2 Actividades a desarrollar **5**

2.1 Actividades de contextualización e identificación de conocimientos 8

2.2 Actividades de apropiación de conocimiento 15

3. Actividad de transferencia de conocimiento 26

3.1 Diccionario de datos 28

1. Actividades

1.1 Actividad de reflexión inicial

2. Caso de estudio:

Durante el pico de la pandemia de COVID-19 en octubre de 2020, el gobierno del Reino Unido, a través de la agencia Public Health England (PHE), dependía de la recopilación masiva de datos para tomar decisiones estratégicas diarias. Estas decisiones incluían la imposición de restricciones de movilidad, la asignación de recursos hospitalarios y, lo más crítico, el rastreo inmediato de contactos de las personas infectadas para contener la propagación del virus. PHE detectó un fallo en la transferencia automatizada de archivos de los laboratorios a sus sistemas. Entre el 25 de septiembre y el 2 de octubre, 15.841 resultados positivos no se incluyeron en las cifras diarias publicadas ni se transfirieron oportunamente al sistema de rastreo de contactos (House of Commons, 2020, p. 625). La nota periodística de Leo Kelion para BBC News explica que los laboratorios comerciales que procesaban las pruebas enviaban los resultados diarios al sistema central de PHE en formato de texto plano (CSV). Posteriormente, un proceso automatizado tomaba estos archivos y los importaba a plantillas de Microsoft Excel en el formato antiguo XLS para que los analistas pudieran consolidar la información y alimentar los tableros de control (dashboards) (Kelion, 2020). El error fatal ocurrió en la elección del formato estructural, el sistema automatizado fue configurado para consolidar los datos utilizando el formato heredado de Excel (.xls), en lugar del formato moderno (.xlsx) o mantener el procesamiento nativo en texto plano (.csv). Al agrupar los resultados de las pruebas en columnas dentro de este archivo heredado, el volumen de datos superó rápidamente el límite de las 65.536 filas. El sistema simplemente cortó los datos excedentes sin generar ninguna alerta de error; al alcanzar el límite, los resultados restantes quedaban fuera del proceso de carga al sistema central. Como resultado directo de esta mala gestión en el formato de los datos, se presentó que exactamente 15.841 resultados positivos de COVID-19 no se registraron en los sistemas centrales. Durante varios días, los tableros de control mostraron una falsa disminución en los casos de conta gio. Los tomadores de decisiones a nivel gubernamental asumieron que las medidas de contención estaban funcionando, cuando en realidad la curva estaba en ascenso. Datos, Información, Toma de Decisiones, Fuentes y Formatos 4 Dado que estos casi 16.000 casos positivos ”desaparecieron” del sistema, no se enviaron a los centros de rastreo. Se estima que alrededor de 50.000 contactos estrechos no fueron advertidos a tiempo de su exposición al virus, lo que aceleró la

propagación en las comunidades (Halliday et al., 2020). El problema afectó la publicación de las cifras y el paso de esos resultados al rastreo, pero no significa que las personas con resultados positivos quedarán sin notificación: el secretario de Salud informó que habían recibido sus resultados y la indicación de aislarse en el plazo habitual (House of Commons, 2020, p. 625). En cambio, se estimó que más de 50.000 contactos cercanos podrían no haber sido localizados oportunamente. Esa cifra es una estimación basada en promedios de contactos por caso, no un conteo confirmado de personas omitidas (Halliday et al., 2020). El incidente dejó incompletos temporalmente los datos de los tableros de control. Sin embargo, el secretario de Salud sostuvo que la información corregida no modificaba sustancialmente la evaluación de la epidemia ni la base de las decisiones locales adoptadas (House of Commons,2020,p.625).

2. Actividades a desarrollar

1. Documentar de manera concisa las diferencias estructurales entre un archivo de texto plano (CSV), un formato de hoja de cálculo heredado (XLS) y uno moderno (XLSX), haciendo énfasis en sus límites de almacenamiento (filas y columnas) e identificando en qué punto exacto falló la integridad de los datos en el caso expuesto

DONDE FALLÓ LA INTEGRIDAD DE LOS DATOS EN EL CASO:

El fallo se produjo debido a que los registros superan el límite del archivo, debido a esto no se generó ninguna alerta de advertencia en el sistema. Por este error se omitieron 15.841 casos positivos de COVID-19. Para finalizar esto llegó afectar los reportes oficiales de las personas contagiadas.

Tabla 1

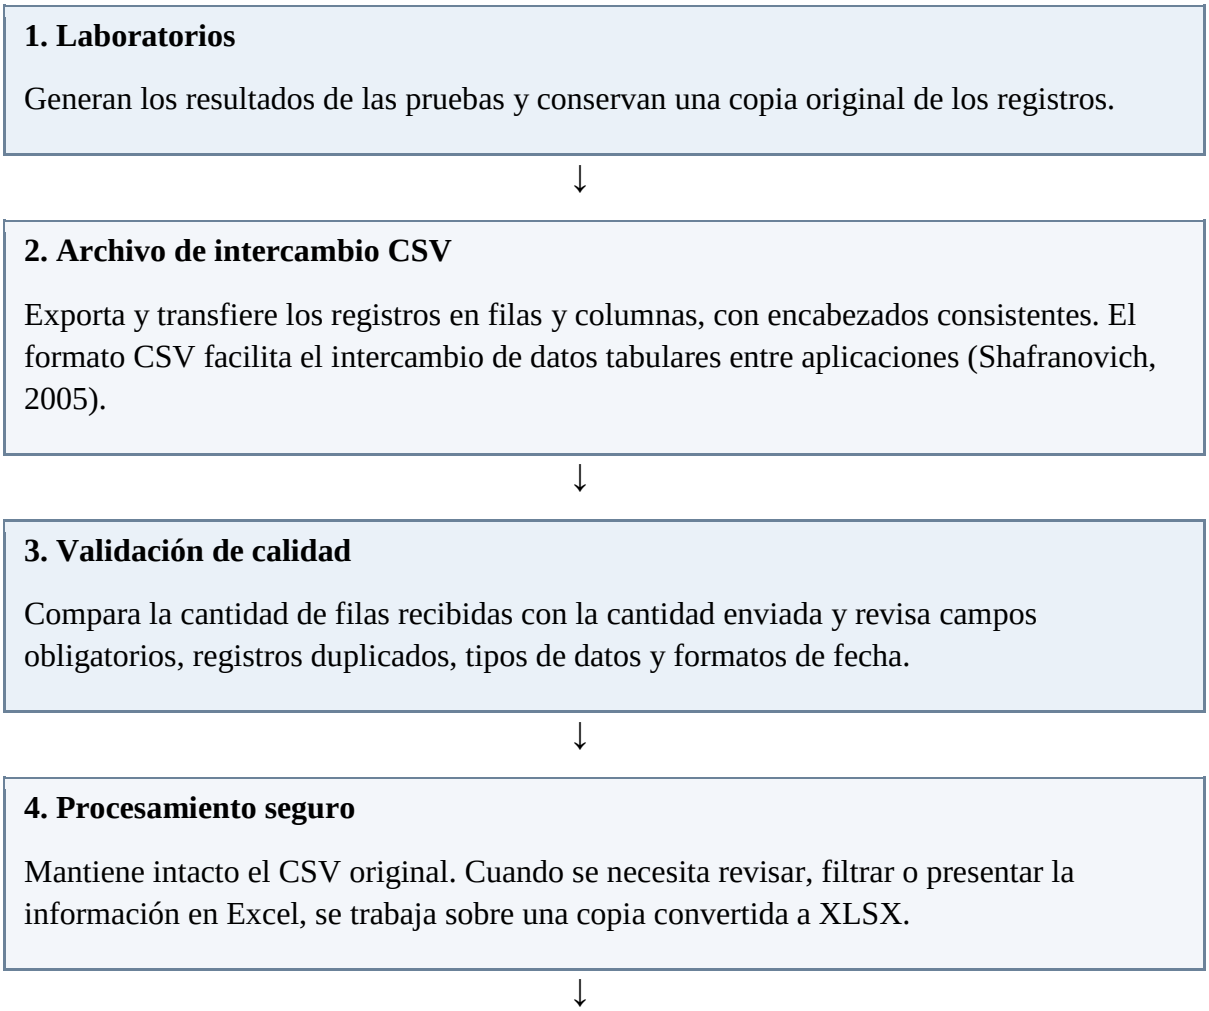
Comparación de los formatos CSV, XLS y XLSX

ASPECTO	CSV	XLS	XLSX
ESTRUCTURA	Es un archivo de texto plano donde los datos de la tabla se separan mediante comas (,).	Libro binario de cálculo antiguo.	Es uno de los formatos más utilizados para hojas de cálculo y es uno de los archivos comprimidos que contiene conjunto de archivos XML.
LÍMITE DE FILAS	Es un formato que no fija un límite universal y depende de la aplicación usada para leerlo.	Filas por hoja 65.536.	Límite de filas 1.048.576 por hoja.
LÍMITE DE COLUMNAS	No tienen un límite técnico o estándar de columnas, ya que son simples archivos de textos planos.	Columnas por hoja 256.	Límite de columnas 16.384 por hoja.
FORMATO Y FUNCIONES	Las funciones corresponden a las capacidades que tiene cada formato para almacenar y gestionar datos.	Admite hojas, fórmulas y formatos de Excel antiguos.	Su función es organizar datos, realizar cálculos y crear gráficos en Excel.
USO RECOMENDADO	El uso recomendado indica en qué situaciones resulta más adecuado emplearla según sus características y limitaciones.	Trabajar con archivos destinados a versiones antiguas de Excel.	Es recomendado para almacenar, organizar y analizar datos con tablas y fórmulas en Excel.

2. Elaborar un esquema conceptual que ilustre cómo debió ser el tránsito seguro de la información desde los laboratorios (origen) hasta el tablero de control gubernamental (destino). Se debe justificar qué formatos (CSV o XLSX) debieron emplearse en cada etapa para garantizar la preservación de los casi 16.000 registros perdidos

Figura 1

Flujo seguro de información desde los laboratorios hasta el tablero de control gubernamental



5. Sistema central y tablero de control gubernamental

Carga únicamente los registros validados, publica cifras verificadas y conserva la trazabilidad para comprobar que los datos coincidan con el archivo original.

JUSTIFICACIÓN DEL ESQUEMA: El esquema nos da una información segura y trazable mediante validaciones de calidad, procesamientos controlados y verificación de los registros. El uso de la CSV que favorece a la interoperabilidad entre sistemas, contribuyendo a mantener la integridad de los datos durante todo el proceso.

3. Redactar una conclusión analítica sobre la relación directa entre el conocimiento técnico del analista de datos y la responsabilidad ética en la toma de decisiones a nivel gerencial o gubernamental.

CONCLUSIÓN:

Lo que pasó con Public Health England nos demuestra que el trabajo de un analista de datos va mucho más allá de los números, es una gran responsabilidad ética. Cuando se tomó la decisión técnica de usar un archivo de Excel que no tenía la capacidad suficiente, el resultado no fue un simple error del sistema, se perdieron miles de registros clave y se terminó afectando la toma de decisiones del gobierno en un momento crítico. Esto nos deja claro que un analista no solo está para procesar datos de forma automática. Su verdadero rol es cuidar la integridad y la confiabilidad de esa información, porque un fallo técnico en el mundo real puede impactar directamente en la vida de la gente.

2.1 Actividades de contextualización e identificación de conocimientos

1. Enunciado del eje temático y justificación

El equipo de trabajo escogió como temática la accidentalidad vial en Bogotá, debido a que es una problemática que afecta la seguridad y la calidad de vida de los ciudadanos. Los accidentes de tránsito pueden ocasionar lesiones, pérdidas humanas, daños materiales y dificultades en la movilidad de la ciudad.

Se considera importante estudiar este tema mediante conjuntos de datos porque permiten identificar características de los accidentes, como su ubicación, fecha, gravedad, tipo de vehículo involucrado y condiciones de las víctimas. A través de esta información se pueden reconocer patrones, identificar zonas con mayor accidentalidad y comprender mejor la situación de la seguridad vial en Bogotá. Además, el análisis de estos datos puede contribuir a proponer medidas de prevención y mejorar la toma de decisiones.

2. Clasificación de las fuentes de información

Los conjuntos de datos que escogimos son fuentes secundarias, porque la información ya había sido recopilada y publicada por otras personas o entidades antes de que nosotros la consultáramos. Por ejemplo, el conjunto de Probabilidad de accidentalidad utiliza información de registros existentes; el de Mortalidad por accidentes de tránsito fue publicado en Datos Abiertos Bogotá, y el de Homicidio en accidente de tránsito se encuentra en Datos Abiertos Colombia. Como equipo, no vamos a recoger la información directamente, sino que vamos a utilizar esos datos para conocer mejor la problemática de los accidentes de tránsito y realizar nuestro propio análisis.

3. Conjuntos de datos encontrados

Tabla 2

Fuentes de datos abiertos sobre accidentes de tránsito

Nombre del conjunto de datos	Portal	Descripción y utilidad	Enlace de acceso
Vehículos involucrados en un accidente	Datos abiertos Colombia	Contiene información sobre los vehículos involucrados en accidentes de tránsito en Bogotá, lo que permite identificar cuáles participan con mayor frecuencia y analizar su relación con la accidentalidad en la ciudad.	https://www.datos.gov.co/Transporte/VEHICULOS-INVOLUCRADOS-EN-UN-ACCIDENTE-DE-TRANSITO/6jmc-vaxk/about_data
Mortalidad por accidentes de tránsito	Datos abiertos Bogotá D. C.	Archivo CSV con variables sobre año, casos, momento del hecho, tipo de accidente, condición de la víctima y medio de transporte.	https://datosabiertos.bogota.gov.co/dataset/mortalidad-por-accidentes-de-transito
Homicidio en accidente de tránsito	Datos abiertos Colombia	Registro de homicidios en accidentes de tránsito con fecha, departamento, municipio y cantidad. Tiene cobertura nacional; para el tema se puede filtrar Bogotá D. C.	https://www.datos.gov.co/Seguridad-y-Defensa/HOMICIDIO-EN-ACCIDENTE-DE-TR-NSITO/uav5-b85g/about_data

4. Clasificación estadística de 30 variables

Tabla 3

Clasificación de las variables de los conjuntos de datos

Conjunto de datos	Variable	Clasificación
vehículos involucrados en accidentes de tránsito	Marca vehículo	cualitativa nominal
vehículo involucrado en accidentes de tránsito	Modelo de vehículo	cuantitativa discreta
Vehículos involucrados en accidentes de tránsito	Tipo de vehículo	cualitativa nominal
Vehículos involucrados en accidentes de tránsito	Edad de vehículo	cuantitativa discreta
vehículos involucrados en accidentes de tránsito	Fecha de accidente	cuantitativa discreta
Vehículos involucrados en accidentes de tránsito	Gravedad de accidente	cualitativa ordinal
vehículos involucrados en accidentes de tránsito	Departamento del accidente	cualitativa nominal
Vehículos involucrados en accidentes de tránsito	Municipio del accidente	cualitativa nominal
vehículos involucrados en accidentes de tránsito	Autoridad de tránsito	cualitativa nominal
Vehículos involucrados en accidentes de tránsito	Derivada fecha del accidente	cuantitativa discreta
Mortalidad por accidente de tránsito	Código de localidad	Cualitativa nominal

Conjunto de datos	Variable	Clasificación
Mortalidad por accidente de tránsito	Casos	Cuantitativa discreta
Mortalidad de accidentes de tránsito	Sexo	cualitativa nominal
Mortalidad de accidentes de tránsito	Mes del accidente	Cualitativa ordinal
Mortalidad de accidentes de tránsito	Dia del accidente	Cuantitativa discreta
Mortalidad de accidentes de tránsito	Rango de hora del accidente	Cualitativa ordinal
Mortalidad de accidentes de tránsito	Pertenencia grupal	Cualitativa nominal
Mortalidad de accidentes de tránsito	País de nacimiento	Cualitativa nominal
Mortalidad de accidentes de tránsito	Clase de accidente	Cualitativa nominal
Mortalidad de accidentes de tránsito	Circunstancia del accidente	Cualitativa nominal
Mortalidad de accidentes de tránsito	Condición de la victima	Cualitativa nominal
Mortalidad de accidentes de tránsito	Medio de transporte	Cualitativa nominal

Conjunto de datos	Variable	Clasificación
Mortalidad de accidentes de tránsito	Objeto de colisión	Cualitativa nominal
Mortalidad de accidentes de tránsito	Ciclo vital	Cualitativa ordinal
Homicidio en accidentes de tránsito	Fecha de hecho	Cuantitativa discreta
Homicidio en accidentes de tránsito	Código de departamento	Cualitativa nominal
Homicidio en accidentes de tránsito	Departamento	Cualitativa nominal
Homicidio en accidentes de tránsito	Código de municipio	Cualitativa nominal
Homicidio en accidentes de tránsito	Municipio	Cualitativa nominal
Homicidio en accidentes de tránsito	Cantidad	Cuantitativa discreta

2.2 Actividades de Apropiación del Conocimiento

Con base en la temática concertada previamente, cada equipo seleccionar y descargara dos (2) datasets reales (obligatoriamente uno en formato CSV y otro en formato XLSX) alojados en los portales explorados. A continuación, ejecutar en una auditoría técnica rigurosa sobre ambos archivos para descubrir y documentar por lo menos seis (6) inconsistencias en los datos. Para la explicación de los problemas encontrados use la siguiente estructura:

• ¿Qué o cuál es el problema?

• ¿Cómo se ha detectado?

• ¿Por qué cree que se trata de un problema?

• ¿Un ejemplo completo extraído del propio dataset?

- Mortalidad por accidentes de tránsito

1. Inconsistencia: datos completos y evitar valores ausentes:

¿Qué o cuál es el problema?

El 0 y el 21, ya que estos no son un código de localidad en Bogotá ni en Colombia.

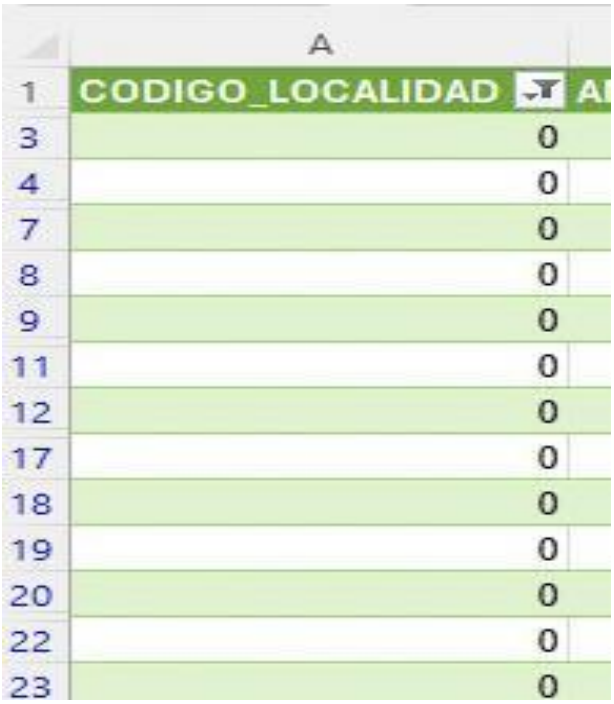
¿Cómo se ha detectado?

Se analizó el archivo y se encontró el error de datos completos y valores ausentes en la columna llamada código de localidad además se investigó en internet si la localidad 0 y 21 existían.

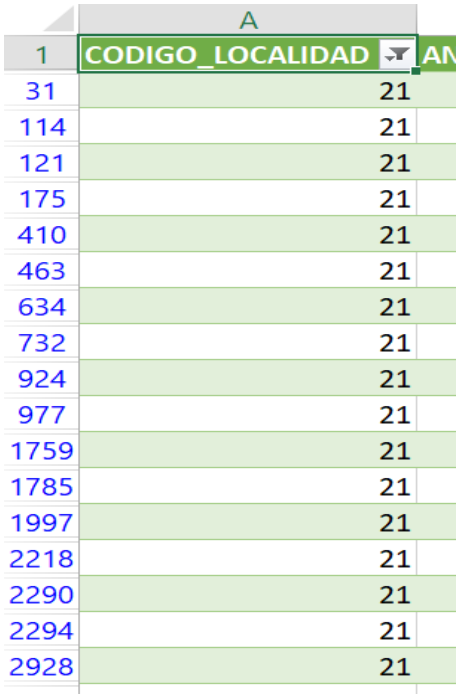
¿Por qué cree que se trata de un problema?

Es un problema porque entre las localidades de Bogotá no existen esos códigos. Ya que al investigar se confirmó que las localidades van del 01 al 20.

¿Un ejemplo completo extraído del propio dataset?



	A
1	CODIGO_LOCALIDAD
3	0
4	0
7	0
8	0
9	0
11	0
12	0
17	0
18	0
19	0
20	0
22	0
23	0



	A
1	CODIGO_LOCALIDAD
31	21
114	21
121	21
175	21
410	21
463	21
634	21
732	21
924	21
977	21
1759	21
1785	21
1997	21
2218	21
2290	21
2294	21
2928	21

2. Inconsistencia: Valores ausentes:

¿Qué o cuál es el problema?

El archivo muestra repetidas veces No aplica, sin información, sin dato dando a entender que no hay un dato existente.

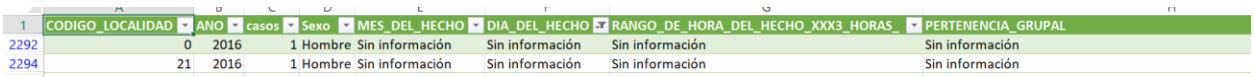
¿Cómo se ha detectado?

Revisando las columnas y buscando se encontró celdas de información que no fue registrada. Se pueden identificar utilizando los filtros de Excel.

¿Por qué cree que se trata de un problema?

Se considera un problema porque se utilizan diferentes expresiones para indicar que no hay información disponible, lo que puede generar confusión al analizar los datos y dificultar la identificación de los registros que realmente no tienen información.

¿Un ejemplo completo extraído del propio dataset?



	CODIGO_LOCALIDAD	ANO	casos	Sexo	MES_DEL_HECHO	DIA_DEL_HECHO	RANGO_DE_HORA_DEL_HECHO_XXX3_HORAS_	PERTENENCIA_GRUPAL
2292	0	2016	1	Hombre	Sin información	Sin información	Sin información	Sin información
2294	21	2016	1	Hombre	Sin información	Sin información	Sin información	Sin información

3. Inconsistencia: Duplicación de datos:

¿Qué o cuál es el problema?

En las filas 9 y 47 Ambas filas contienen exactamente los mismos valores en todas sus columnas, podrían ser registros duplicados, lo que puede afectar los resultados de un análisis.

¿Cómo se ha detectado?

Revisando las columnas y buscando se encontró celdas de información que no fue registrada. Se pueden identificar utilizando los filtros de Excel.

¿Por qué cree que se trata de un problema?

Porque la misma información podría estar registrada más de una vez, lo que puede aumentar incorrectamente la cantidad de accidentes y puede llegar a alterar los resultados de los análisis.

¿Un ejemplo completo extraído del propio dataset?

	CODIGO_LOCALIDAD	ANO	casos	Sexo	MES_DEL_HECHO	DIA_DEL_HECHO	RANGO_DE_HORA_DEL_HECHO_XXX3_HORAS_	PERTENENCIA_GRUPAL
9	0	2015	1	Hombre	julio	domingo	03:00 a 05:59	Ninguno
47	0	2015	1	Hombre	julio	domingo	03:00 a 05:59	Ninguno

4. Inconsistencia: Estandarizar valores de datos

¿Qué o cuál es el problema?

El mismo medio de transporte aparece registrado de dos maneras diferentes, lo que puede hacer que los datos se separen en categorías distintas y se nos dificulte saber cuántos accidentes estuvieron relacionados con aviones o avionetas.

¿Cómo se ha detectado?

Ordenando y revisando las categorías de una columna para encontrar diferentes formas de escribir un mismo dato. Por ejemplo: avión-avioneta / avión,Avioneta.

¿Por qué cree que se trata de un problema?

Porque la información puede quedar separada en categorías diferentes, aunque haga referencia a los mismos medios de transporte, lo que puede llegar a dificultar el identificar y contar correctamente los accidentes relacionados con los aviones y las avionetas.

¿Un ejemplo completo extraído del propio dataset?

	L	M	N	O	P	Q	R
1	CONDICION_DE_LA_VICTIMA_AT_	MEDIO_DE_DESPLAZAMIENTO_O_TRANSPORTE	OBJETO_DE_COLISION	LOCALIDAD	ANCESTRO_RACIAL	PERTENENCIA_ETNICA	CICLO_VITAL
54	Pasajero	Avión – avioneta	No aplica	Bogotá	Mestizo	Sin información	(29 a 59) Adultez
55	Pasajero	Avión – avioneta	No aplica	Engativá	Sin Información	Sin información	(29 a 59) Adultez
56	Conductor	Avión – avioneta	No aplica	Engativá	Mestizo	Sin información	(29 a 59) Adultez
57	Pasajero	Avión – avioneta	No aplica	Engativá	Mestizo	Sin información	(29 a 59) Adultez
58	Pasajero	Avión – avioneta	No aplica	Bogotá	Sin Información	Sin información	(29 a 59) Adultez
59	Conductor	Avión – avioneta	No aplica	Bogotá	Mestizo	Sin información	(29 a 59) Adultez
60	Pasajero	Avión – avioneta	No aplica	Engativá	Mestizo	Sin información	(29 a 59) Adultez
61	Pasajero	Avión – avioneta	No aplica	Bogotá	Mestizo	Sin información	(29 a 59) Adultez
5522	Pasajero	Avión, Avioneta	No aplica	Bogotá	Mestizo	Sin Pertenencia Étnica	(29 a 59) Adultez
5523	Pasajero	Avión, Avioneta	No aplica	Usaquén	Mestizo	Sin Pertenencia Étnica	(Más de 60) Adulto Mayor
5524	Pasajero	Avión, Avioneta	No aplica	Bogotá	Mestizo	Sin Pertenencia Étnica	(Más de 60) Adulto Mayor
5525	Pasajero	Avión, Avioneta	No aplica	Suba	Sin Información	Sin Pertenencia Étnica	(18 a 28) Juventud
5526	Conductor	Avión, Avioneta	No aplica	Usaquén	Sin Información	Sin Pertenencia Étnica	(29 a 59) Adultez
5527	Conductor	Avión, Avioneta	No aplica	Bogotá	Sin Información	Sin Pertenencia Étnica	(29 a 59) Adultez
5528	Pasajero	Avión, Avioneta	No aplica	Bogotá	Sin Información	Sin Pertenencia Étnica	(18 a 28) Juventud
5529	Pasajero	Avión, Avioneta	No aplica	Suba	Mestizo	Sin Pertenencia Étnica	(29 a 59) Adultez

5. Inconsistencia: Duplicidad de categorías en las circunstancias del accidente

¿Qué o cuál es el problema?

En la columna de circunstancias del accidente aparecen varias categorías con nombres diferentes, como “Otro”, “Otra” y “Otras circunstancias”, aunque hacen referencia a la misma clasificación y esto puede generar confusión y dividir la información al momento de analizar los datos.

¿Cómo se ha detectado?

Indagando entre las columnas nos dimos de cuenta que en el apartado de circunstancias del accidente se encontraban varias categorías con nombres distintos pero haciendo referencia a la misma clasificación.

¿Por qué cree que se trata de un problema?

Porque la información queda dividida en varias categorías que representan prácticamente lo mismo, lo que puede generar confusión y dificultar el análisis de los datos.

¿Un ejemplo completo extraído del propio dataset?

3414	Colombia	Choque	Otro	Conductor	Bicicleta	Automóvil	Los Mártires	Mestizo
1117	Colombia	Choque	Otra	Pasajero	Automóvil	Automóvil	Barrios Unidos	Blanco
31	Colombia	Volcamiento	Otras circunstancias no especificadas	Conductor	Automóvil	No aplica	Sin dato	Mestizo

6. Inconsistencia: Inconsistencia en el registro de vehículos:

¿Qué o cuál es el problema?

El tipo de vehículo aparece escrito de dos formas diferentes: “Tracto-camión” y “Tractocamión”, aunque ambas hacen referencia al mismo vehículo. Esto puede hacer que la información se divida en dos categorías al momento de analizar los datos.

¿Cómo se ha detectado?

Se detectó el error al revisar y comparar los valores de la columna de tipo de vehículo, donde se encontró que “Tracto-camión” y “Tractocamión” aparecen escritos de manera diferente, haciendo referencia a el mismo vehículo.

¿Por qué cree que se trata de un problema?

Porque al momento de contar cuántos tractocamiones estuvieron involucrados en accidentes, los resultados podrían no ser exactos, ya que algunos aparecen registrados con un nombre y otros con el otro.

¿Un ejemplo completo extraído del propio dataset?

981	Desobedecer señales de tránsito	Peatón	No aplica	Tracto – camión	Kennedy	Mestizo	Sin información	(Más de 60) Adulto Mayor
983	Desobedecer señales de tránsito	Peatón	No aplica	Tracto – camión	Bogotá	Mestizo	Sin información	(18 a 28) Juventud
1032	Desobedecer señales de tránsito	Peatón	No aplica	Tracto – camión	Bogotá	Mestizo	Sin información	(29 a 59) Adultez
1060	Sin información	Peatón	No aplica	Tracto – camión	Fontibón	Mestizo	Sin información	(29 a 59) Adultez
1067	Otras circunstancias no especificadas	Peatón	No aplica	Tracto – camión	Bogotá	Mestizo	Sin información	(Más de 60) Adulto Mayor
1171	Otra	Conductor	Bicicleta	Tractocamión	Bogotá	Mestizo	Sin información	(29 a 59) Adultez
1207	Otra	Conductor	Bicicleta	Tractocamión	Bosa	Mestizo	Sin información	(29 a 59) Adultez
1217	Exceso de velocidad	Conductor	Bicicleta	Tractocamión	Bosa	Mestizo	Sin información	(18 a 28) Juventud
1270	Exceso de velocidad	Conductor	Bicicleta	Tractocamión	Bogotá	Mestizo	Sin información	(18 a 28) Juventud
1338	Sin información	Conductor	Motocicleta	Tractocamión	Bogotá	Mestizo	Sin información	(18 a 28) Juventud
1342	Otra	Conductor	Motocicleta	Tractocamión	Bogotá	Mestizo	Sin información	(18 a 28) Juventud
1360	Desobedecer señales de tránsito	Conductor	Motocicleta	Tractocamión	Kennedy	Mestizo	Sin información	(18 a 28) Juventud
1380	Sin información	Conductor	Motocicleta	Tractocamión	Suba	Mestizo	Sin información	(29 a 59) Adultez
1392	Otra	Conductor	Motocicleta	Tractocamión	Engativá	Mestizo	Sin información	(29 a 59) Adultez
1398	Embriaguez (Alcohólica y no alcohólica)	Conductor	Motocicleta	Tractocamión	Kennedy	Mestizo	Sin información	(18 a 28) Juventud
1424	Exceso de velocidad	Pasajero	Motocicleta	Tractocamión	Puente Aranda	Mestizo	Sin información	(29 a 59) Adultez
1449	Sin información	Conductor	Motocicleta	Tractocamión	Bogotá	Mestizo	Sin información	(29 a 59) Adultez
1451	Otra	Pasajero	Motocicleta	Tractocamión	Tunjuelito	Mestizo	Sin información	(12 a 17) Adolescencia

- Vehículos involucrados en un accidente

1. Inconsistencia: Formateo de variables de fecha y hora

¿Qué o cuál es el problema?

Se identificó un error en la ubicación de la fecha. Los valores correspondientes al día, mes y año no se encuentran registrados en sus respectivos campos, incumpliendo la estructura definida de la base de datos.

¿Cómo se ha detectado?

Al revisar la estructura de la base de datos, se identificó que los componentes de la fecha (día, mes y año) aparecen registrados en casillas diferentes a las definidas, generando una inconsistencia en la organización de la información.

¿Por qué cree que se trata de un problema?

Es un problema debido a que incumple la estructura definida para la base de datos, lo que puede ocasionar inconsistencias en el almacenamiento, consulta y procesamiento de la información, y teniendo en cuenta la norma ISO 8601 la estructura principal es de (de mayor a menor): Año, mes, día, hora, minutos, segundos y fracciones de segundo.

¿Un ejemplo completo extraído del propio dataset?

	E
1	FECHA_ACCIDENTE
2096	1/08/2026
2097	1/08/2026
2213	1/08/2026
2214	1/08/2026
2310	1/08/2026
2311	1/08/2026
2457	1/08/2026
2458	1/08/2026
2464	1/08/2026
2465	1/08/2026
2537	1/08/2026
2538	1/08/2026
2758	1/07/2026
2768	1/07/2026
2769	1/07/2026
3117	1/07/2026
3118	1/07/2026
3193	1/07/2026

2. Inconsistencia: Formateo de datos numéricos

¿Qué o cuál es el problema?

El problema consiste en que algunos datos numéricos del dataset presentan valores que no corresponden con la información que deberían representar. Por ejemplo, en la columna de edad

del vehículo aparecen números demasiado elevados, como 127, 118 y 1826 años, que no son edades normales para un vehículo.

¿Cómo se ha detectado?

Se detectó al revisar y comparar los valores de las columnas numéricas del archivo, especialmente la columna correspondiente a la edad de los vehículos. Al observar los registros, se encontraron números que se salen de los rangos esperados y que no coinciden con la realidad.

¿Por qué cree que se trata de un problema?

Considero que es un problema porque los datos numéricos deben tener un formato correcto y representar información real. Si se ingresan números equivocados o valores que no tienen sentido, se pueden alterar los resultados de los análisis estadísticos y generar información incorrecta al momento de utilizar estos datos para entrenar modelos de inteligencia artificial

¿Un ejemplo completo extraído del propio dataset?

1	MARCA_VEHICULO	MODELO_VEHICULO	TIPO_VEHICULO	EDAD_VEHICULO	FEC
4884	INTERNATIONAL	2008	CAMION	118	
15209	AUTECO BAJAJ	2008	MOTOCICLETA	127	
18061	MAZDA	1995	AUTOMOVIL	127	
18514	CITROEN	1995	AUTOMOVIL	118	
26515	KENWORTH	2007	TRACTOCAMION	2020	
27125	HONDA	2008	MOTOCICLETA	127	
27196	HONDA	2007	MOTOCICLETA	127	
33847	CHEVROLET	1992	AUTOMOVIL	127	
46888	KAWASAKI	1979	MOTOCICLETA	127	
49676	MAZDA	1993	CAMIONETA	127	
55981	HONDA	2008	MOTOCICLETA	127	
63790	YAMAHA	2009	MOTOCICLETA	127	
63793	YAMAHA	2009	MOTOCICLETA	127	
66305	HONDA	1992	MOTOCICLETA	127	
81024	HONDA	2009	MOTOCICLETA	127	
93773	YAMAHA	2009	MOTOCICLETA	127	
112686	HONDA	2009	MOTOCICLETA	127	
124832	YAMAHA	2009	MOTOCICLETA	127	

3. Inconsistencia: estandarizar valores de datos

¿Qué o cuál es el problema?

Se presenta un posible error en la forma de registrar la información geográfica, ya que en la columna departamento aparece "Bogotá D.C." y en municipio aparece "Bogotá". Es necesario verificar si estos valores cumplen con la clasificación establecida para el dataset.

¿Cómo se ha detectado?

Se detectó al revisar y comparar las columnas departamento y municipio, observando que Bogotá aparece con dos denominaciones diferentes, lo que generó dudas sobre la organización de la información.

¿Por qué cree que se trata de un problema?

Consideramos que podría ser un problema si los datos no siguen un mismo criterio de clasificación, ya que esto puede generar confusiones al organizar, filtrar o analizar la información por ubicación geográfica.

¿Un ejemplo completo extraído del propio dataset?

1	DEPARTAMENTO_ACCIDENTE	MUNICIPIO_ACCIDENTE
19569	BOGOTA D.C.	BOGOTA
20027	BOGOTA D.C.	BOGOTA
20028	BOGOTA D.C.	BOGOTA
20426	BOGOTA D.C.	BOGOTA
20427	BOGOTA D.C.	BOGOTA
20463	BOGOTA D.C.	BOGOTA
20655	BOGOTA D.C.	BOGOTA
20656	BOGOTA D.C.	BOGOTA
20939	BOGOTA D.C.	BOGOTA
20942	BOGOTA D.C.	BOGOTA
21397	BOGOTA D.C.	BOGOTA
21513	BOGOTA D.C.	BOGOTA
21514	BOGOTA D.C.	BOGOTA
21538	BOGOTA D.C.	BOGOTA
21540	BOGOTA D.C.	BOGOTA
21674	BOGOTA D.C.	BOGOTA
21675	BOGOTA D.C.	BOGOTA
21753	BOGOTA D.C.	BOGOTA

4. Inconsistencia: Datos completos y evitar valores ausentes

¿Qué o cuál es el problema?

El problema consiste en que existen registros donde la variable EDAD_VEHICULO aparece vacía, es decir, no contiene ningún dato que permita conocer la edad del vehículo involucrado en el accidente.

¿Cómo se ha detectado?

Se detectó al revisar el dataset y verificar las columnas que contenían información incompleta. Durante esta revisión se encontraron 20 registros sin ningún valor en la columna correspondiente a la edad del vehículo.

¿Por qué cree que se trata de un problema?

Considero que es un problema porque la falta de información afecta la calidad y la confiabilidad del dataset. Al no conocer la edad de algunos vehículos, se dificulta realizar análisis completos y obtener resultados precisos. Además, si estos datos se utilizan para entrenar modelos de inteligencia artificial, la información incompleta puede afectar los resultados.

¿Un ejemplo completo extraído del propio dataset?

	A	B	C	D	
1	MARCA_VEHICULO	MODELO_VEHICULO	TIPO_VEHICULO	EDAD_VEHICULO	FEC
33443	HERO	2025	MOTOCICLETA		
36258	CHEVROLET	2017	AUTOMOVIL		
121822	CHEVROLET	2017	AUTOMOVIL		
122413	HONDA	2010	MOTOCICLETA		
179468	DODGE	2017	CAMIONETA		
179503	CHEVROLET	2017	AUTOMOVIL		
179987	SUZUKI	2017	MOTOCICLETA		
267011	AKT	2023	MOTOCICLETA		
267013	AKT	2023	MOTOCICLETA		
278337	SUZUKI	2017	MOTOCICLETA		
318922	SUZUKI	2012	MOTOCICLETA		
328899	SUZUKI	2015	MOTOCICLETA		
341792	SUZUKI	2017	MOTOCICLETA		
384592	DODGE	2012	CAMIONETA		
384595	DODGE	2012	CAMIONETA		
392944	SUZUKI	2017	MOTOCICLETA		
420335	SUZUKI	2016	MOTOCICLETA		
428308	HONDA	2017	MOTOCICLETA		

5. Inconsistencia: Error de estandarización y formato de datos de texto**.**

¿Qué o cuál es el problema?

Se observa que el nombre de la autoridad de tránsito está registrado utilizando abreviaturas y una estructura poco clara, lo que dificulta identificar correctamente el nombre completo de la entidad.

¿Cómo se ha detectado?

Se detectó al revisar la columna AUTORIDAD DE TRÁNSITO en Excel, donde se encontró el mismo nombre registrado con abreviaturas y caracteres que dificultan su interpretación.

¿Por qué cree que se trata de un problema?

Considero que es un problema porque la información no está estandarizada y puede generar dificultades al momento de clasificar, buscar, agrupar y analizar los datos. También puede ocasionar que una misma autoridad sea identificada como si fueran entidades diferentes

¿Un ejemplo completo extraído del propio dataset?

	G	H	I
1	DEPARTAMENTO_ACCIDENTE	MUNICIPIO_ACCIDENTE	AUTORIDAD_DE_TRANSITO
2096	MAGDALENA	SANTA MARTA	U TEC CONT/VIG/ REG TTOyTTE SANTA MARTA
2097	MAGDALENA	SANTA MARTA	U TEC CONT/VIG/ REG TTOyTTE SANTA MARTA
2213	MAGDALENA	SANTA MARTA	U TEC CONT/VIG/ REG TTOyTTE SANTA MARTA
2214	MAGDALENA	SANTA MARTA	U TEC CONT/VIG/ REG TTOyTTE SANTA MARTA
2310	MAGDALENA	SANTA MARTA	U TEC CONT/VIG/ REG TTOyTTE SANTA MARTA
2311	MAGDALENA	SANTA MARTA	U TEC CONT/VIG/ REG TTOyTTE SANTA MARTA
2457	MAGDALENA	SANTA MARTA	U TEC CONT/VIG/ REG TTOyTTE SANTA MARTA
2458	MAGDALENA	SANTA MARTA	U TEC CONT/VIG/ REG TTOyTTE SANTA MARTA
2464	MAGDALENA	SANTA MARTA	U TEC CONT/VIG/ REG TTOyTTE SANTA MARTA
2465	MAGDALENA	SANTA MARTA	U TEC CONT/VIG/ REG TTOyTTE SANTA MARTA
2537	MAGDALENA	SANTA MARTA	U TEC CONT/VIG/ REG TTOyTTE SANTA MARTA
2538	MAGDALENA	SANTA MARTA	U TEC CONT/VIG/ REG TTOyTTE SANTA MARTA
2758	MAGDALENA	SANTA MARTA	U TEC CONT/VIG/ REG TTOyTTE SANTA MARTA
2768	MAGDALENA	SANTA MARTA	U TEC CONT/VIG/ REG TTOyTTE SANTA MARTA
2769	MAGDALENA	SANTA MARTA	U TEC CONT/VIG/ REG TTOyTTE SANTA MARTA
3117	MAGDALENA	SANTA MARTA	U TEC CONT/VIG/ REG TTOyTTE SANTA MARTA
3118	MAGDALENA	SANTA MARTA	U TEC CONT/VIG/ REG TTOyTTE SANTA MARTA
3193	MAGDALENA	SANTA MARTA	U TEC CONT/VIG/ REG TTOyTTE SANTA MARTA

6. Inconsistencia: Inconsistencia en la estandarización de categorías

¿Qué o cuál es el problema?

Se identifican diferentes categorías para representar una misma marca de vehículo. En este caso, Mercedes-Benz aparece escrito de dos maneras distintas en la columna MARCA VEHÍCULO.

¿Cómo se ha detectado?

Se detectó al revisar las categorías de la columna MARCA VEHÍCULO y comparar los nombres registrados. Se encontraron diferencias en la escritura de una misma marca, específicamente por el uso del guión.

¿Por qué cree que se trata de un problema?

Considero que es un problema porque puede generar duplicidad de categorías y afectar los resultados de los análisis. Por ejemplo, al contar cuántos vehículos Mercedes-Benz estuvieron involucrados en accidentes, Excel podría contabilizar ambas formas de escritura por separado, dando resultados divididos.

¿Un ejemplo completo extraído del propio dataset?

	MARCA_VEHICULO
12489	MERCEDES BENZ
12598	MERCEDES BENZ
12616	MERCEDES BENZ
12768	MERCEDES BENZ
13032	MERCEDES BENZ
13180	MERCEDES BENZ
13218	MERCEDES BENZ
13240	MERCEDES BENZ
13339	MERCEDES-BENZ
13442	MERCEDES BENZ
13655	MERCEDES BENZ
13896	MERCEDES BENZ
14043	MERCEDES BENZ
14445	MERCEDES BENZ
14572	MERCEDES-BENZ
14734	MERCEDES BENZ
14890	MERCEDES-BENZ
15098	MERCEDES BENZ
15111	MERCEDES BENZ

3. Actividades de Transferencia de Conocimiento

El equipo de trabajo seleccionará el dataset que consideren más robusto de los dos auditados en la fase anterior. Utilizando la información contenida en dicho archivo, procederá a documentar técnicamente la estructura completa del archivo mediante un instrumento de metadatos (Diccionario de datos).

3.1 Desarrollo del Diccionario de Datos

Para cada variable (columna) del dataset principal seleccionado, el equipo construirá una matriz registrando rigurosamente:

- Mortalidad por accidentes de tránsito

1. Nombre original de la variable: (Tal cual aparece en el archivo fuente)
2. Nombre estandarizado sugerido: Propuesta de nombre técnico sin espacios, sin tildes y en minúsculas por ejemplo (promedio_nota).
3. Clasificación estadística: Cualitativa (nominal/ordinal) o Cuantitativa (discreta/continua).

4.Tipo de dato técnico: Cadena De Texto, numérico entero, numérico decimal, fecha, booleano, arreglo o colección, null.

5. Descripción semántica: Explicación precisa de qué representa esa columna o atributo en el contexto de su temática.

6. Unidad de medida o formato: (ej. COP, metros, porcentaje, formato DD/MM/AAAA).

Tabla 4

Diccionario de datos: mortalidad por accidentes de tránsito

DICCIONARIO DE DATOS – MORTALIDAD POR ACCIDENTES DE TRÁNSITO

Nombre original de la variable	Nombre estandarizado sugerido	Clasificación estadística	Tipo de dato técnico	Descripción semántica	Unidad de medida o formato
(En blanco)	codigo_localidad	Cualitativa nominal	Numérico entero	Código numérico asociado a la localidad donde se registra el hecho. El encabezado original está vacío, por lo que esta interpretación debe confirmarse.	Código numérico entero
ANO	ano	Cuantitativa discreta	Numérico entero	Año en el que ocurrió el accidente de tránsito.	Año (AAAA)
casos	cantidad_casos	Cuantitativa discreta	Numérico entero	Cantidad de casos de mortalidad registrados en cada fila.	Número entero
Sexo	sexo	Cualitativa nominal	Cadena de texto	Sexo de la víctima involucrada en el accidente.	Categoría de texto
MES_DEL_HECHO	mes_del_hecho	Cualitativa nominal	Cadena de texto	Mes del año en el que ocurrió el accidente.	Nombre del mes
DIA_DEL_HECHO	dia_del_hecho	Cualitativa nominal	Cadena de texto	Día de la semana en el que ocurrió el accidente.	Nombre del día
RANGO_DE_HORA_DEL_HECHO_XXX3_HORAS_	rango_hora_hecho	Cualitativa ordinal	Cadena de texto	Intervalo de tres horas en el que ocurrió el accidente.	Rango horario (HH:MM a HH:MM)
PERTENENCIA_GRUPAL	pertenencia_grupal	Cualitativa nominal	Cadena de texto	Grupo o condición de pertenencia con la que se identifica o registra a la víctima.	Categoría de texto
PAIS_DE_NACIMIENTO	pais_de_nacimiento	Cualitativa nominal	Cadena de texto	País en el que nació la víctima.	Nombre del país

DICCIONARIO DE DATOS – MORTALIDAD POR ACCIDENTES DE TRÁNSITO					
CLASE_O_TIPO_DE_ACCIDENTE_DE_TRANSPORTE	tipo_accidente_transporte	Cualitativa nominal	Cadena de texto	Clasificación del tipo de accidente de transporte ocurrido.	Categoría de texto
CIRCUNSTANCIA_DEL_HECHO_DETALLADA	circunstancia_hecho	Cualitativa nominal	Cadena de texto	Describe la circunstancia o situación relacionada con el accidente.	Categoría de texto
CONDICION_DE_LA_VICTIMA_AT_	condicion_victima	Cualitativa nominal	Cadena de texto	Indica el papel que tenía la víctima en el momento del accidente, por ejemplo, conductor o pasajero.	Categoría de texto
MEDIO_DE_DESPLAZAMIENTO_O_TRANSPORTE	medio_transporte	Cualitativa nominal	Cadena de texto	Medio de transporte en el que se desplazaba la víctima.	Categoría de texto
OBJETO_DE_COLISION	objeto_colision	Cualitativa nominal	Cadena de texto	Objeto o elemento con el que se produjo la colisión.	Categoría de texto
LOCALIDAD	localidad	Cualitativa nominal	Cadena de texto	Localidad o zona geográfica de Bogotá asociada al accidente.	Nombre de la localidad o zona
ANCESTRO_RACIAL	ancestro_racial	Cualitativa nominal	Cadena de texto	Clasificación del ancestro racial registrada para la víctima.	Categoría de texto
PERTENENCIA_ETNICA	pertenencia_etnica	Cualitativa nominal	Cadena de texto	Información sobre la pertenencia étnica de la víctima.	Categoría de texto
CICLO_VITAL	ciclo_vital	Cualitativa ordinal	Cadena de texto	Grupo de edad al que pertenece la víctima según las etapas del ciclo vital.	Rango de edad en años y categoría

4.REFERENCIA

- Secretaría Distrital de Salud. (s. f.). Mortalidad por accidentes de tránsito. Observatorio de Salud de Bogotá – SaluData. Recuperado el 6 de noviembre de 2026, de https://saludata.saludcapital.gov.co/osb/indicadores/mortalidad-de-accidentes-de-transito/
- Ministerio de Transporte. (2026, 4 de septiembre). Vehículos involucrados en un accidente de tránsito Ley 2251-2022 [Conjunto de datos]. Portal Nacional de Datos Abiertos. https://www.datos.gov.co/Transporte/VEHICULOS-INVOLUCRADOS-EN-UN-ACCIDENTE-DE-TRANSITO/6jmc-vaxk
- Ministerio de Defensa Nacional. (s. f.). Homicidio en accidente de tránsito. Datos Abiertos Colombia. https://www.datos.gov.co/Seguridad-y-Defensa/HOMICIDIO-EN-ACCIDENTE-DE-TR-NSITO/uav5-b85g
- Microsoft. (s. f.). Formatos de archivo que admite Excel. Soporte técnico de Microsoft. https://support.microsoft.com/es-es/excel/file-formats-that-are-supported-in-excel
- Microsoft. (s. f.). Excel formatting and features that are not transferred to other file formats. Microsoft Support. https://support.microsoft.com/en-us/excel/excel-formatting-and-features-that-are-not-transferred-to-other-file-formats
- Ministerio de Tecnologías de la Información y las Comunicaciones. (s. f.). Definición del Marco de Interoperabilidad. Lenguaje Común de Intercambio de Información. https://lenguaje.mintic.gov.co/marco

NOTA: Para el desarrollo de la guía se utilizó inteligencia artifial en los siguientes puntos:

- En la figura 1 se utilizó el 30% para la realización
- En la tabla 2 se utilizó 10% para analizar y comprender como realizar una tabla con normas apa
- En el diccionario de datos se utilizó un 20% para verificar que si cumpliera con las normas
- Se utilizó Copilot y chatgpt